

Especificação da Etapa 5 do Projeto de Compilador

Geração de Código

A quinta etapa do trabalho de implementação de um compilador para a **Linguagem Amarela** consiste na geração de código intermediário a partir da árvore sintática abstrata (AST). Utilizaremos como representação intermediária a **Linguagem ILOC**, descrita em detalhes no apêndice A de *Engineering a Compiler* [?], mas com o essencial na seção A deste documento. Testes poderão ser realizados através de um simulador simples escrito em Python3 e já disponível no repositório git de referência (em *scripts*, etapa 5, ilocsim).

Atenção: Eventuais alterações na gramática podem ser necessárias para realizar a geração de código em uma única passagem (juntamente com a análise léxica, sintática e semântica). O grupo pode optar por fazer o processo de geração de código em uma segunda passagem sobre a AST.

1 Funcionalidades Necessárias

Os resultados compreendem a correção dos problemas encontrados na etapa anterior e estas funcionalidades.

1.1 Suporte para Arranjos Multidimensionais em Amarela

A gramática da linguagem deve ser alterada para suportar arranjos multidimensionais. A sintaxe de declaração é tipo nome[num,...,num];. A sintaxe no acesso a elementos dos arranjos é, por exemplo, id[num,num] para um arranjo de duas dimensões. O num é um inteiro positivo. No acesso a um elemento, o valor de num pode ser calculado a partir de uma expressão aritmética. Arranjos podem ser declarados como variáveis globais, locais, e dentro de escopos aninhados, mas não podem ser passados como parâmetro para uma função. Um exemplo completo utilizando arranjos na linguagem Amarela:

```
float arranjo[10,40,30];
int funcao_com_arranjos ()
{
   int a;
   int b;
   float c;
   arranjo[a+b,b+c,10*a] = 3;
   a = arranjo[a+b,b+c,10*a];
}
```

1.2 Implementação de uma Estrutura de Dados para ILOC

Um novo módulo deve ser adicionado ao projeto de compilador para fornecer uma estrutura com o código da operação e os argumentos necessários para cada operação (consulte a Seção A.5 para saber quais são as operações válidas em ILOC e seus argumentos). Note que os argumentos das operações são nomes de registradores, valores constantes, ou nomes de rótulos.

1.3 Gerenciamento de Rótulos e Registradores

Um novo módulo deve ser adicionado ao projeto de compilador para fornecer rótulos a serem utilizados na geração de código. Os nomes dos rótulos gerados são utilizados para marcar os pontos de desvio no fluxo de execução e devem seguir a convenção de nomes especificada na Seção A.

A Linguagem ILOC estabelece que todas as operações devem ser feitas sobre valores que estão em registradores. Por causa disso, um novo módulo deve ser adicionado ao projeto de compilador para gerenciar a criação de nomes de registradores. Os nomes de registradores devem seguir a convenção de nomes especificada na Seção A. Os registradores podem ser vistos como variáveis auxiliares.



1.4 Geração de Código

Implemente uma função que percorre a AST recursivamente, retornando um trecho de código intermediário ILOC (lista de TACs) para cada nó visitado. Essa rotina primeiro processa os nós filhos, armazena os trechos de código gerados para cada um deles, depois gera o código correspondente ao nó atual considerando o código dos filhos e o código sintetizado no próprio nó. A geração consiste, em geral, na criação de uma ou mais novas instruções ILOC, união de trechos das sub-árvores e dessas novas instruções, opcionalmente com a criação de novos símbolos intermediários e rótulos, retornando um trecho de código completo desse novo nó. A geração de código deve traduzir, nesta etapa do projeto, as seguintes construções da Linguagem **Amarela**:

- Declaração de variáveis (cálculo de endereço)
 - Endereço de variáveis locais são um deslocamento em relação ao registrador especial fp (rarp)
 - Endereço de variáveis globais são um deslocamento em relação ao registrador especial rbss
- Expressões Aritméticas
- Expressões Booleanas (com curto-circuito)
- Arranjos Multidimensionais
- Comandos de Atribuição
- Comandos de Fluxo de Controle

Por questões de simplicidade nesta etapa, os programas em **Amarela** deverão conter apenas uma função chamada main.

2 Discussão Importante

Na tradução para ILOC, deve-se considerar que o conteúdo de cada variável da Linguagem Amarela está em um endereço de memória. Este endereço deve ser calculado no momento da declaração da variável considerando o escopo atual e seu endereço base. Antes de realizar qualquer operação sobre uma variável, deve-se antes de tudo carregar o seu conteúdo (a partir de um endereço de memória) para um registrador (utilizando a operação load, por exemplo), para só então realizar a operação sobre a variável. Ao final desta operação, o valor resultante estará obrigatoriamente em um registrador. Este valor final deve ser transferido para o endereço da variável na memória (utilizando a operação store, por exemplo).

3 Dicas de Desenvolvimento

Abaixo listam-se algumas dicas de desenvolvimento que podem ser úteis.

Instruções

As instruções em código intermediário servem para isolar as tarefas de geração da sequência básica de instruções dos detalhes e formato específicos de uma arquitetura alvo. Além disso, a geração usada nesse trabalho emprega técnicas genéricas de forma funcional, didática, mas pode ser otimizada de várias formas antes da geração de código assembly. Dois exemplos de otimização são a reutilização de símbolos temporários em expressões e o uso de registradores. Entretanto, essas otimizações não fazem parte desta etapa do trabalho e são portanto opcionais.

Geração de Código

A geração de código será feita de baixo para cima e da esquerda para a direita, na árvore. O modo mais simples de encadear novas instruções é representar os trechos de código como listas encadeadas invertidas, isto é, com um ponteiro para a última instrução de um trecho, e cada instrução apontando para a anterior. Ao final da geração, escreva uma função que percorre o código completo e inverte a lista de forma que se possa escrever o código na ordem em que deve ser executado.



Funções Auxiliares

Para a geração de código, além das rotinas utilitárias de TACs e da rotina recursiva principal que percorre a AST, utilize outras funções auxiliares. Isto tem dois motivos: primeiro, a semelhança na geração de código em vários nós da árvore, especialmente nas expressões aritméticas e relacionais. Segundo, evitar o tamanho da função de geração. Ela deve realizar um switch(node->type) e chamar a função auxiliar de geração de código apropriada para o tipo deste nó da AST.

Entrada e Saída Padrão

Organize a sua solução para que o compilador leia o programa em **Amarela** da entrada padrão e gere o programa em ILOC na saída padrão. Dessa forma, pode-se realizar o seguinte comando (considerando que main é o binário do compilador):

./main < entrada.iks > saida.iloc

Onde entrada.iks contém um programa em Amarela, e saida.iloc contém o programa em ILOC correspondente.

4 Requisitos Obrigatórios

Os requisitos obrigatórios são os mesmos da seção equivalente na especificação das etapas anteriores do projeto de compilador. O ambiente de compilação e execução desta etapa podem ser definidos da seguinte forma:

- \$ git pull origin master
- \$ cmake -DETAPA_1=OFF -DETAPA_2=OFF -DETAPA_3=OFF -DETAPA_4=OFF -DETAPA_5=ON ..
- \$ make

Para os testes da avaliação automática, basta executar o comando:

ctest -R e5

Caso os testes falhem, utilize a opção -V com o comando ctest.

5 Dúvidas

Crie um novo tópico no fórum de discussão do projeto de compilador no moodle.

Bom trabalho!



A A Linguagem ILOC

ILOC¹ é uma representação intermediária parecida com assembly para uma máquina RISC abstrata. A máquina abstrata que executa ILOC tem um número ilimitado de registradores. ILOC é um código de três endereços com operações de registrador a registrador, operações de carga (load) e armazenamento (store), comparações e desvios. Suporta apenas modos de endereçamento simples, tais como – direto, endereço + offset, endereço + imediato, e imediato. Os operandos são lidos no início do ciclo quem uma operação começa a ser executada. Os operandos resultantes da operação se tornam definidos no final do ciclo no qual a operação se completa.

A.1 Gramática da Linguagem ILOC

Um programa ILOC consiste em uma lista sequencial de instruções. Cada instrução pode ser precedida por um rótulo. Um rótulo é apenas uma cadeia de caracteres sendo separada da instrução por dois pontos. Por convenção, limita-se o formato dos rótulos com a expressão regular [a-z]([a-z]|[0-9]|-)*. Se alguma instrução precisa de mais de um rótulo, deve ser inserido uma instrução que contém apenas um operação nop antes dela, colocando o rótulo adicional na instrução nop. Um programa ILOC é definido mais formalmente:

 $\begin{array}{cccc} \operatorname{ProgramaILOC} & \to & \operatorname{ListaInstrucoes} \\ \operatorname{ListaInstrucoes} & \to & \operatorname{Instrucao} \\ & & | & \operatorname{label} \colon \operatorname{Instrucao} \\ & | & \operatorname{Instrucao} \operatorname{ListaInstrucoes} \end{array}$

Cada instrução pode conter uma ou mais operações. Uma instrução com uma única operação é escrita em uma linha própria, enquanto que uma instrução com múltiplas operações pode ser escrita em várias linhas. Para agrupar operações em uma instrução única, nós envolvemos a lista de operações entre colchetes e separamos cada operações com ponto e vírgulas. Mais formalmente:

Uma operação ILOC corresponde a uma instrução em nível de máquina que pode ser executada por uma única unidade funcional em um único ciclo. Ela tem um código de operação (opcode), uma sequência de operandos fontes separados por vírgulas, e uma sequência de operandos alvo separados também por vírgulas. Os operandos fonte são separados dos operandos alvo pelo símbolo =>, que significa "em". Formalmente:

Operacao
OperacaoNormal
OperacaoFluxoControle
OperacaoNormal
Operacao ListaOperandos ⇒ ListaOperandos
ListaOperandos
Operando

O não-terminal *Codigo Operacao* pode ser qualquer operação ILOC, exceto cbr, jump, e jumpI. As tabelas na seção A.5 mostram o número de operandos e seus tipos para cada operação da Linguagem ILOC.

Um *Operando* pode ser um de três tipos: registrador, numero e rotulo. O tipo de cada operando é determinado pelo código da operação e a posição que o operando aparece na operação. Por convenção, os registradores começam pela letra r (minúscula) e são seguidos por um número inteiro ou uma cadeia de caracteres qualquer. Ainda por convenção, rótulos sempre começam pela letra L (maiúscula).

A maioria das operações tem um único operando alvo; algumas operações de armazenamento (store) tem operandos alvos múltiplos, assim como saltos. Por exemplo, storeAI tem um único operando fonte e dois operandos alvo. A fonte deve ser um registrador, e os alvos devem ser um registrador e uma constante imediata. Então, a operação da linguagem ILOC:

¹Este texto é uma tradução simplificada do apêndice A do livro do Keith [?].



storeAI ri => rj,4

calcula o endereço adicionando 4 ao conteúdo de rj e armazena o valor encontrado no registrador ri na localização da memória especificada pelo endereço calculado. Em outras palavras:

Operações de fluxo de controle tem uma sintática diferente. Uma vez que estas operações não definem seus alvos, elas são escritas com uma flecha simples -> ao invés da flecha dupla =>. Formalmente:

A primeira operação, cbr, implementa um desvio condicional. As outras duas operações são desvios incondicionais.

A.2 Convenções de Nome

O código ILOC usa um conjunto simples de convenções de nome.

- 1. Deslocamentos de memória para variáveis são representados simbolicamente com um **0** antes do nome da variável.
- 2. Existe um número ilimitado de registradores. Estes são nomeados com inteiros simples, como r1789, ou com nomes simbólicos, como em ri ou rj.
- 3. O registrador rarp é reservado como um ponteiro para o registro de ativação atual. Sendo assim, a operação:

carrega o conteúdo da variável x, guardada no deslocamento @x a partir do rarp, em r1.

Comentários em ILOC começam com // e continuam até o final da linha.

A.3 Operações Individuais

A.3.1 Aritmética

A Linguagem ILOC tem operações de três endereços de registrador para registrador.

Opcode	Fonte	Alvo	Significado
add	r1, r2 =	> r3	73 = r1 + r2
sub	r1, r2 =	> r3	r3 = r1 - r2
mult	r1, r2 =	> r3	r3 = r1 * r2
div	r1, r2 =	> r3	r3 = r1/r2
addI	r1, c2 =	> r3	r3 = r1 + c2
subI	r1, c2 =	> r3	r3 = r1 - c2
rsubI	r1, c2 =	> r3	r3 = c2 - r1
${\tt multI}$	r1, c2 =	> r3	r3 = r1 * c2
divI	r1, c2 =	> r3	r3 = r1/c2
rdivI	r1, c2 =	> r3	r3 = c2/r1

Todas estas operações realizam a leitura dos operandos origem de registradores ou constantes e escrevem o resultado de volta para um registrador. Qualquer registrador pode servir como um operando origem ou destino.

As primeiras quatro operações da tabela são operações registrador para registrador clássicas. As próximas seis especificam um operando imediato. As operações não comutativas, sub e div, tem duas formas imediatas alternativas para permitir o operando imediato em qualquer lado do operador. As formas imediatas são úteis para expressar resultados de certas otimizações, para escrever exemplos de forma mais concisa, e para registrar jeitos óbvios de reduzir a demanda por registradores.



A.3.2 Shifts

ILOC suporta um conjunto de operações aritméticas de *shift*, para a esquerda e para a direita, em ambas as formas, com registradores e imediata.

Opcode	Fonte		Alvo	Significado
lshift	r1, r2	=>	r3	$r3 = r1 \ll r2$
lshiftI	r1, c2	=>	r3	$\begin{vmatrix} r3 = r1 << c2 \\ r3 = r1 >> r2 \end{vmatrix}$
rshift	r1, r2	=>	r3	r3 = r1 >> r2
${\tt rshiftI}$	r1, c2	=>	r3	r3 = r1 >> c2

A.3.3 Operações sobre a Memória

ILOC suporta um conjunto de operadores de carga e armazenamento para mover valores entre a memória e registradores. As operações load e cload movem dados da memória para os registradores.

Opcode	Fonte		Alvo	Significado
load	r1	=>	r2	r2 = Memoria(r1)
loadAI	r1, c2	=>	r3	r3 = Memoria(r1 + c2)
loadA0	r1, r2	=>	r3	r3 = Memoria(r1 + r2)
cload	r1	=>	r2	caractere load
cloadAI	r1, c2	=>	r3	caractere loadAI
${\tt cloadA0}$	r1, r2	=>	r3	caractere loadA0

As operações diferem nos modos de endereçamento que elas suportam. As operações load e cload assumem um endereço direto na forma de um único operando registrador. As operações loadAI e cloadAI adicionam um valor imediato ao conteúdo do registrador para formar um endereço imediatamente antes de realizar a carga. Nós chamamos estas de operações de endereçamento imediato. As operações loadAO e cloadAO adicionam o conteúdo de dois registradores para calcular o endereço efetivo imediatamente antes de realizar a carga. Estas operações são chamadas de endereçamento por deslocamento.

Uma outra forma de carga que a Linguagem ILOC suporta é uma operação loadI de carga imediata. Ela recebe um inteiro como argumento e coloca este inteiro dentro do registrador alvo.

Opcode	Fonte		Alvo	Significado
loadI	c1	=>	r2	r2 = c1

As operações de armazenamento são semelhantes, conforme a tabela abaixo.

Opcode	Fonte	Alvo		Significado
store	r1	=>	r2	$\mid \text{Memoria}(r2) = r1$
storeAI	r1	=>	r2, c3	Memoria(r2+c3) = r1
storeA0	r1	=>	r2, r3	Memoria(r2+r3) = r1
cstore	r1	=>	r2	caractere store
cstoreAI	r1	=>	r2, c3	caractere storeAI
cstoreA0	r1	=>	r2, r3	caractere storeAO

Não há nenhuma operação de armazenamento imediato.

A.3.4 Operações de Cópia entre Registradores

A Linguagem ILOC tem um conjunto de operações para mover valores entre registradores, sem passar pela memória.



Opcode	Fonte		Alvo	Significado
i2i	r1	=>	r2	r2 = r1 para inteiros
c2c	r1	=>	r2	r2 = r1 para caracteres
c2i	r1	=>	r2	converte um caractere para um inteiro
i2c	r1	=>	r2	converte um inteiro para caractere

As primeiras duas operações, i2i e c2c, copiam um valor de um registrador para outro, sem conversão. As duas últimas operações realizam conversões considerando a codificação de caracteres ASCII.

A.4 Operações de Fluxo de Controle

Em geral, operações de comparação na Linguagem ILOC recebem dois valores e retornam um valor booleano.

Opcode	Fonte		Alvo	Significado
cmp_LT	r1, r2	->	r3	r3 = true se r1 < r2, señão r3 = false
$\mathtt{cmp} LE$	r1, r2	->	r3	$r3 = true \text{ se } r1 \leq r2, \text{ senão } r3 = false$
${\tt cmp_EQ}$	r1, r2	->	r3	r3 = true se r1 = r2, senão r3 = false
$\mathtt{cmp_GE}$	r1, r2	->	r3	$r3 = true \text{ se } r1 \ge r2, \text{ senão } r3 = false$
$\mathtt{cmp_GT}$	r1, r2	->	r3	r3 = true se r1 > r2, senão r3 = false
$\mathtt{cmp}_{\mathtt{NE}}$	r1, r2	->	r3	$r3 = true \text{ se } r1 \neq r2, \text{ señão } r3 = false$
cbr	r1	->	12, 13	PC = l2 se $r1 = true$, senão $PC = l3$

A operação condicional cbr recebe um booleano como argumento e transfere o controle para um de dois rótulos alvo. Os dois rótulos alvo não precisam estar definidos previamente (pode-se saltar para um código mais a frente do programa).

A.4.1 Saltos

A Linguagem ILOC tem duas formas de operações de salto. A primeira é um salto incondicional e imediato que transfere o controle para um a primeira instrução após um rótulo. A segunda recebe um registrador como argumento. O conteúdo do registrador é interpretado como um endereço de código, transferindo o controle incondicionalmente e imediatamente para este endereço. Esta segunda forma deve ser evitada por ser ambígua. Mais detalhes a respeito disto na referência oficial [?].

Opcode	Fonte		Alvo	Significado
jumpI		->	11	PC = l1
jump		->	r1	PC = r1



A.5 Sumário de Operações ILOC

A.5.1 Sumários de Operações ILOC Individuais

Opcode	Fonte	Alvo	Significado
nop			não faz nada
add sub	r1, r2 => r1, r2 =>	r3	r3 = r1 + r2 r3 = r1 - r2 r3 = r1 * r2
mult div	r1, r2 => r1, r2 =>		$ \begin{array}{c c} r3 = r1 * r2 \\ r3 = r1/r2 \end{array} $
addI subI rsubI multI divI	r1, c2 => r1, c2 => r1, c2 => r1, c2 => r1, c2 =>	r3 r3 r3	r3 = r1 + c2 $r3 = r1 - c2$ $r3 = c2 - r1$ $r3 = r1 * c2$ $r3 = r1/c2$
rdivI lshift lshiftI rshift rshiftI	r1, c2 => r1, r2 => r1, c2 => r1, r2 => r1, r2 =>	r3 r3 r3	
and andI or orI xor xorI	r1, r2 => r1, c2 => r1, r2 => r1, c2 => r1, r2 => r1, c2 =>	r3 r3 r3 r3	$r3 = r1 \land r2$ $r3 = r1 \land c2$ $r3 = r1 \lor r2$ $r3 = r1 \lor c2$ $r3 = r1 \text{ xor } r2$ $r3 = r1 \text{ xor } c2$
loadI	c1 =>	r2	r2 = c1
load loadAI loadAO	r1 => r1, c2 => r1, r2 =>	r3	r2 = Memoria(r1) r3 = Memoria(r1 + c2) r3 = Memoria(r1 + r2)
cload cloadAI cloadAO	r1 => r1, c2 => r1, r2 =>	r3	caractere load caractere loadAI caractere loadAO
store storeAI storeAO	r1 => r1 => r1 =>	r2, c3	$\begin{array}{l} \operatorname{Memoria}(r2) = r1 \\ \operatorname{Memoria}(r2 + c3) = r1 \\ \operatorname{Memoria}(r2 + r3) = r1 \end{array}$
cstore cstoreAI cstoreAO	r1 => r1 => r1 =>	r2, c3	caractere store caractere storeAI caractere storeAO
i2i c2c c2i i2c	r1 => r1 => r1 =>	r2 r2	r2 = r1 para inteiros r2 = r1 para caracteres converte um caractere para um inteiro converte um inteiro para caractere



A.5.2 Sumários de Operações ILOC de Fluxo de Controle

Opcode	Fonte		Alvo	Significado
jumpI		->	11	PC = l1
jump		->	r1	PC = r1
cbr	r1	->	12, 13	PC = l2 se $r1 = true$, senão $PC = l3$
cmp_LT	r1, r2	->	r3	r3 = true se $r1 < r2$, senão $r3 = false$
$\mathtt{cmp} _LE$	r1, r2	->	r3	$r3 = true \text{ se } r1 \leq r2, \text{ senão } r3 = false$
${\tt cmp_EQ}$	r1, r2	->	r3	r3 = true se r1 = r2, senão r3 = false
$\mathtt{cmp_GE}$	r1, r2	->	r3	$r3 = true \text{ se } r1 \ge r2, \text{ senão } r3 = false$
$\mathtt{cmp_GT}$	r1, r2	->	r3	r3 = true se r1 > r2, señão r3 = false
cmp_NE	r1, r2	->	r3	$r3 = true$ se $r1 \neq r2$, senão $r3 = false$